Artificial Neural Networks (ANN)

Atıl Samancıoğlu

1 Artificial Neural Networks (ANN)

1.1 Giriş: Perceptron'dan ANN'ye Geçiş

Önceki bölümde tek katmanlı perceptron modelini inceledik. Bu modelin yalnızca **lineer ayrılabilir** problemleri çözebildiğini gördük.

Gerçek hayattaki problemler ise çoğu zaman:

- Lineer değildir
- Birden fazla değişkenin birlikte etkisini içerir
- Karmaşık karar sınırları gerektirir

Bu nedenle tek bir nöron yeterli olmaz. Çözüm olarak, birden fazla nöronun ve katmanın birlikte çalıştığı **Artificial Neural Network (ANN)** yapıları kullanılır.

Bu bölümün amacı:

- ANN mimarisini netleştirmek
- Forward propagation ve backward propagation mantığını sezgisel olarak kurmak

—

1.2 Örnek Problem: Genişletilmiş Öğrenci Verisi

Bu doküman boyunca tek bir örnek üzerinden ilerleyeceğiz.

Bir öğrencinin:

- IQ (x_1)
- Günlük çalışma süresi (x_2)
- Günlük oyun süresi (x_3)

bilgilerine bakarak dersten geçip geçmeyeceğini tahmin etmek istiyoruz.

Çıkış değişkeni ikilidir:

$$y \in \{0, 1\}$$

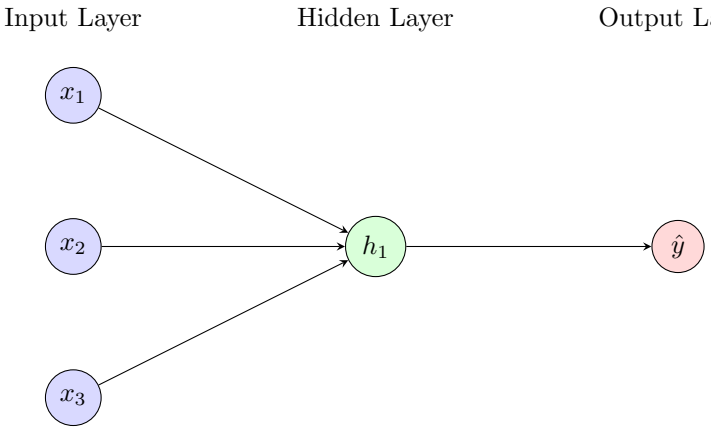
Örnek bir öğrenci:

$$x_1 = 95, \quad x_2 = 4, \quad x_3 = 4, \quad y = 1$$

—

1.3 Çok Katmanlı Sinir Ağı Mimarisi

Aşağıda kullandığımız ANN mimarisi gösterilmektedir:



Bu mimaride:

- 3 giriş özelliği
- 1 gizli nöron
- 1 çıkış nöronu

bulunmaktadır.

Bu yapı, perceptron'dan daha güçlüdür ancak hâlâ anlaşılması kolaydır.

—

1.4 Forward Propagation Nedir?

Forward propagation, girdilerin ağ içerisinde **soldan sağa doğru** işlenmesidir.

Her nöronda aynı iki adım gerçekleşir:

1. Girdilerin ağırlıklarla çarpılıp toplanması
2. Sonucun bir aktivasyon fonksiyonundan geçirilmesi

—

1.5 Ağırlıklar Neden Rastgele Başlatılır?

Eğitime başlarken ağın:

- Doğru ağırlıkları bilmesi mümkün değildir
- Bu nedenle ağırlıklar **küçük rastgele değerlerle** başlatılır

Eğer tüm ağırlıklar sıfırdan başlatılsaydı:

- Tüm nöronlar aynı şeyi öğrenirdi
- Öğrenme gerçekleşmezdi

Bu yüzden pratikte ağırlıklar:

- Küçük
- Rastgele
- Simetriyi bozacak şekilde

başlatılır.

—

1.6 Hidden Layer: Sayısal Forward Hesabı

Gizli katmandaki nöron için hesaplanan değer:

$$z_1 = w_1x_1 + w_2x_2 + w_3x_3 + b_1$$

Başlangıç değerlerini (örnek amaçlı) şu şekilde seçelim:

$$w_1 = 0.01, \quad w_2 = 0.02, \quad w_3 = 0.03, \quad b_1 = 0.001$$

Yerine koyarsak:

$$z_1 = (95 \cdot 0.01) + (4 \cdot 0.02) + (4 \cdot 0.03) + 0.001$$

$$z_1 = 1.151$$

Bu değer, nöronun ürettiği **ham sinyaldir**.

—

1.7 Aktivasyon: Nöronun Tepkisi

Ham sinyal doğrudan kullanılmaz. Sigmoid aktivasyon fonksiyonu uygulanır:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

$$o_1 = \sigma(1.151) \approx 0.759$$

Bu değer:

- Nöronun ne kadar aktif olduğunu gösterir
- Bir sonraki katmana aktarılır

—

1.8 Output Layer: Nihai Tahmin

Çıkış nöronunda hesaplama:

$$z_2 = o_1 \cdot w_4 + b_2$$

Varsayalım:

$$w_4 = 0.02, \quad b_2 = 0.03$$

$$z_2 = (0.759 \cdot 0.02) + 0.03 = 0.04518$$

Sigmoid uygulanır:

$$\hat{y} = \sigma(0.04518) \approx 0.511$$

Bu değer modelin tahminidir:

- 0'a yakınsa: kalma
- 1'e yakınsa: geçme

—

1.9 Loss (Hata) Nedir?

Gerçek çıktı:

$$y = 1$$

Tahmin:

$$\hat{y} = 0.511$$

Aradaki fark modelin hatasını gösterir. Amaç, bu farkı eğitim sürecinde azaltmaktır.

—

1.10 Backward Propagation: Öğrenme Nerede Oluyor?

Backward propagation:

- Hatanın kaynağını bulur
- Ağırlıkları bu hataya göre günceller

Bu işlem:

- Önce çıkış katmanından

- Sonra gizli katmana doğru

ilerler.

Bu sayede ağ, her adımda biraz daha doğru tahmin yapmayı öğrenir.

—

1.11 Özet

Artificial Neural Networks:

- Perceptron'un genişletilmiş halidir
- Öğrenme forward ve backward propagation ile gerçekleşir
- Karmaşık problemleri çözebilir

Bir sonraki bölümde, **backward propagation matematiğini** adım adım inceleyeceğiz.