ReLU, Leaky ReLU, Parametric ReLU ve GELU

Atıl Samancıoğlu

1 Neden Yeni Aktivasyon Fonksiyonlarına İhtiyaç Duyduk?

Sigmoid ve tanh fonksiyonlarını incelediğimizde şunu gördük:

- Derin ağlarda **vanishing gradient problemi** ortaya çıkıyor
- Ağırlıklar yeterince güncellenemiyor
- Eğitim çok yavaşlıyor veya tamamen duruyor

Bu problemleri çözmek için geliştirilen en önemli aktivasyon fonksiyonlarından biri:

ReLU (Rectified Linear Unit)

—

2 ReLU Aktivasyon Fonksiyonu

2.1 Tanım

ReLU fonksiyonu son derece basittir:

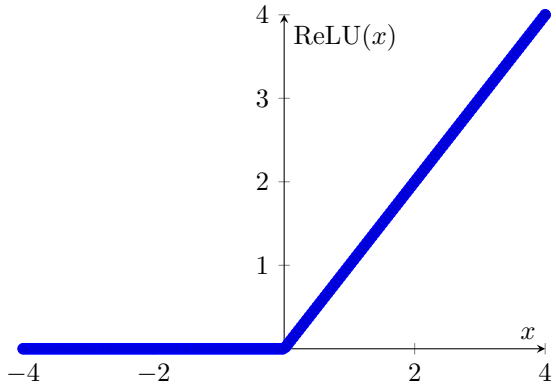
$$\text{ReLU}(x) = \max(0, x)$$

Yani:

- $x > 0$ ise çıktı x
- $x \leq 0$ ise çıktı 0

—

2.2 ReLU Grafiği



—

2.3 ReLU Türevi

Backpropagation açısından kritik nokta türevdir:

$$\text{ReLU}'(x) = \begin{cases} 1, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

Bu şu anlama gelir:

- Pozitif bölgede gradyan **kaybolmaz**
- Vanishing gradient problemi büyük ölçüde çözülür

—

2.4 ReLU'nun Avantajları

- Vanishing gradient problemini büyük ölçüde çözer
- Hesaplama olarak çok hızlıdır
- Modern derin ağların temelidir

—

2.5 ReLU'nun Problemi: Dead Neuron

ReLU'nun ciddi bir problemi vardır:

> *Eğer bir nöron sürekli negatif değer alıyorsa, çıktısı hep 0 olur.*

Bu durumda:

Yani Relu'nun problemi ne mülakat sorusu ölü nöronlar.

- Türevi 0 olur
- Ağırlıklar güncellenmez
- Nöron tamamen “ölür”

Bu duruma:

Dead ReLU (Dead Neuron) Problemi

denir.

—

3 Leaky ReLU

Dead neuron problemini çözmek için ReLU biraz değiştirilmiştir.

3.1 Tanım

$$\text{Leaky ReLU}(x) = \begin{cases} x, & x > 0 \\ \alpha x, & x \leq 0 \end{cases}$$

Burada:

$$\alpha \ll 1 \quad \text{(genellikle 0.01)}$$

—

3.2 Leaky ReLU Grafiği

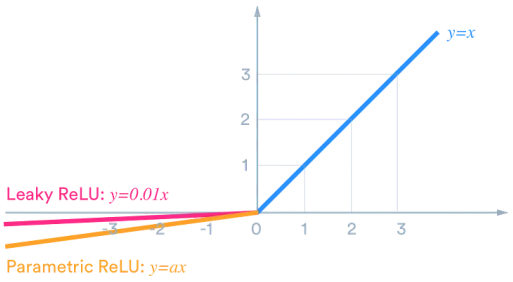


Figure 1: Step (Basamak) Aktivasyon Fonksiyonu

—

3.3 Leaky ReLU Ne Sağlar?

- Negatif bölgede türev sıfır olmaz
- Dead neuron problemi büyük ölçüde çözülür
- ReLU'nun hız avantajı korunur

—

4 Parametric ReLU (PReLU)

Leaky ReLU'nun bir adım ötesi:

4.1 Tanım

$$\text{PReLU}(x) = \begin{cases} x, & x > 0 \\ \alpha x, & x \leq 0 \end{cases}$$

Fark:

- α sabit değildir
- Eğitim sırasında öğrenilir

Yani:

Negatif eğimi modelin kendisi öğrenir.

—

4.2 Avantajları

- Dead neuron problemi yok
- Daha esnek bir yapı
- Özellikle CNN'lerde etkilidir

—

4.3 Dezavantajı

- Ek parametre öğrenilir
- Overfitting riski artabilir

—

5 GELU (Gaussian Error Linear Unit)

Modern transformer tabanlı modellerde (BERT, GPT vb.) en sık kullanılan aktivasyon fonksiyonudur.

—

5.1 Sezgisel Tanım

GELU şunu yapar:

> *Bir değeri tamamen kapatmak yerine, olasılıksal olarak geçirir.*

Yani ReLU gibi sert bir eşik yoktur.

—

5.2 Matematiksel Tanım

$$\text{GELU}(x) = x \cdot \Phi(x)$$

Burada $\Phi(x)$:

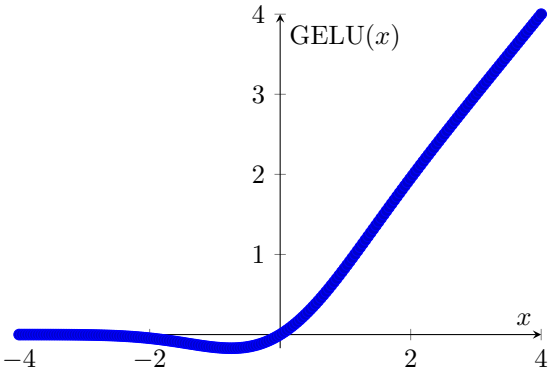
- Standart normal dağılımın kümülatif dağılım fonksiyonu (CDF)

Pratikte kullanılan yaklaşık form:

$$\text{GELU}(x) \approx 0.5x \left(1 + \tanh\left[\sqrt{\frac{2}{\pi}}(x + 0.044715x^3)\right]\right)$$

—

5.3 GELU Grafiği



—

5.4 GELU Neden Güçlü?

- ReLU gibi hızlı
- Tanh gibi yumuşak
- Gradient akışı çok stabil
- Transformer mimarileri için ideal

—

6 Kısa Karşılaştırma

	ReLU	Leaky ReLU	PReLU	GELU
Vanishing Gradient	Hayır	Hayır	Hayır	Hayır
Dead Neuron	Evet	Hayır	Hayır	Hayır
Zero-Centered	Hayır	Hayır	Hayır	Kısmen
Hesaplama Hızı	Çok hızlı	Çok hızlı	Hızlı	Daha yavaş
Modern Kullanım	Yaygın	Yaygın	Orta	Çok yaygın

—

7 Özet

- ReLU, deep learning'i mümkün kıldı
- Leaky ReLU ve PReLU, dead neuron problemini çözdü
- GELU, modern transformer modellerinin standardı oldu

Bir sonraki adımda:

- Aktivasyon fonksiyonları **nerede kullanılır?**
- Hidden layer vs Output layer seçimleri

konusuna geçebiliriz.