Regression için Loss Fonksiyonları

Atıl Samancıoğlu

1 Regression Problemlerinde Loss Neyi Ölçer?

Regression problemlerinde amacımız şudur:

> *Tahmin edilen değer ($\hat{y}$) ile gerçek değer (y) arasındaki farkı mümkün olduğunca azaltmak*

Bu fark:

- Modelin ne kadar iyi öğrendiğini
- Ağırlıkların doğru yönde güncellenip güncellenmediğini

gösterir.

Bu farkı ölçmek için **loss fonksiyonları** kullanılır.

—

2 Mean Squared Error (MSE)

2.1 Tanım

Tek bir veri noktası için loss:

$$L = (y - \hat{y})^2$$

Tüm veri seti için cost:

$$J = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

—

2.2 Sezgisel Anlatım

Hata:

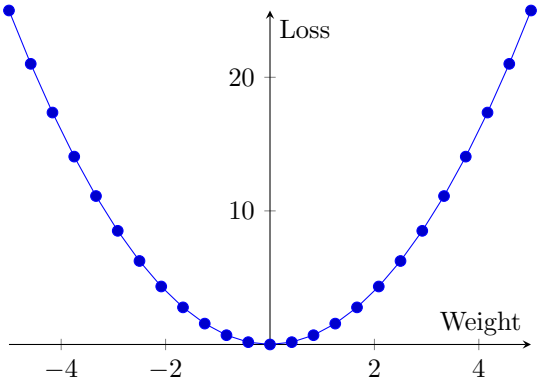
$$y - \hat{y}$$

şeklindedir. MSE bu hatayı **karesini alarak** büyütür.

Büyük hatalar daha sert cezalandırılır.

—

2.3 Geometrik Anlam



Bu parabol:

- Tek bir global minimum içerir
- Gradient descent için idealdir

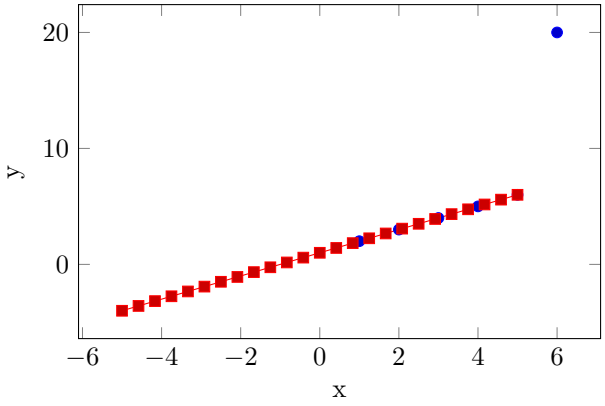
—

2.4 Avantajlar

- Türevlenebilir (smooth)
- Gradient descent ile hızlı yakınsar
- Tek global minimum vardır

—

2.5 Dezavantajlar: Outlier Problemi



Tek bir uç değer (outlier), tüm modeli ciddi şekilde etkileyebilir.

Sebep: hata **karesinin alınması**.

—

3 Mean Absolute Error (MAE)

3.1 Tanım

Loss:

$$L = |y - \hat{y}|$$

Cost:

$$J = \frac{1}{n} \sum_{i=1}^{n} |y_i - \hat{y}_i|$$

—

3.2 Sezgisel Anlatım

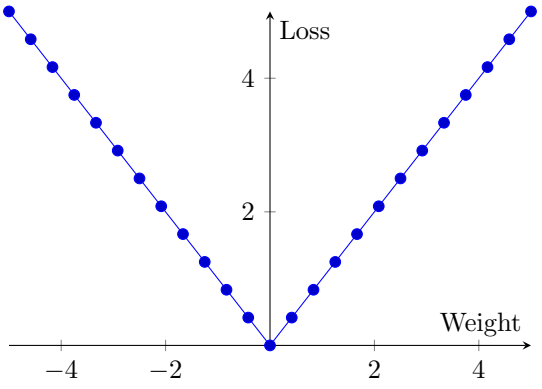
MAE:

- Hatayı büyütmez
- Her hataya eşit davranır

Outlier varsa panik yapmaz.

—

3.3 Geometrik Görünüm



—

3.4 Avantajlar

- Outlier'lara dayanıklıdır
- Gerçek hayata daha uygundur

—

3.5 Dezavantajlar

- Türev her noktada tanımlı değildir
- Gradient descent daha yavaş yakınsar
- Sub-gradient kullanılır

—

4 Huber Loss

4.1 Neden Huber Loss?

ortasını bulmak için geliştirilmiş bi fonksiyon

"MSE çok hassas, MAE çok yavaş. İkisinin ortası yok mu?"

Var: **Huber Loss**

—

4.2 Tanım

$$L = \begin{cases} \frac{1}{2}(y - \hat{y})^2 & \text{if } |y - \hat{y}| \leq \delta \\ \delta|y - \hat{y}| - \frac{1}{2}\delta^2 & \text{otherwise} \end{cases}$$

Burada:

- δ : eşik (hyperparameter)

—

4.3 Sezgisel Anlatım

- Küçük hatalarda: MSE gibi
- Büyük hatalarda: MAE gibi

Akıllı bir kompromis.

—

5 Root Mean Squared Error (RMSE)

5.1 Tanım

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

—

5.2 Neden Kullanılır?

- Hata, hedef değişkenle aynı ölçekte olur
- Yorumu daha kolaydır

"Modelim ortalama kaç birim hata yapıyor?" sorusunun cevabı.

—

6 Hangi Loss Ne Zaman?

Durum	Önerilen Loss
Outlier yok	MSE
Outlier var	MAE
Hem hızlı hem dayanıklı	Huber
Yorum kolaylığı	RMSE

—

7 Özet

- MSE: hızlı ama hassas
- MAE: dayanıklı ama yavaş
- Huber: dengeli çözüm
- RMSE: raporlama dostu

Bir sonraki bölümde:

- Classification loss fonksiyonları
- Binary Cross-Entropy
- Categorical Cross-Entropy

incelenecektir.